

Caracterización de equipos informáticos mediante clustering en una red empresarial

Octubre de 2020

Javier Artiga Garijo

Dirigido por Luis Miguel Garay Gallastegui

INTRODUCCIÓN

INTRODUCCIÓN

- ¿Podemos clasificar en categorías relevantes las direcciones IP de una gran red empresarial, según su comportamiento de red?
- ¿Cuáles serían esas categorías?
- ¿Seremos capaces de identificar comportamientos sospechosos en base a esta clasificación?

INTRODUCCIÓN

- ¿Podemos clasificar en categorías relevantes las direcciones IP de una gran red empresarial, según su comportamiento de red?
- ¿Cuáles serían esas categorías?
- ¿Seremos capaces de identificar comportamientos sospechosos en base a esta clasificación?
- Objetivo:

“Diseñar y probar un sistema que categorice los equipos finales de una red empresarial y detecte comportamientos anómalos.”

ESTADO DEL ARTE

- Aprendizaje automático en clasificación de tráfico
- Detección de anomalías sobre actividad de red
- Clustering

ESTADO DEL ARTE

- Aprendizaje automático en clasificación de tráfico
 - Enfoques basados en flujos
 - Enfoques basados en hosts
- Detección de anomalías sobre actividad de red
- Clustering

ESTADO DEL ARTE

- Aprendizaje automático en clasificación de tráfico
 - Enfoques basados en flujos
 - Enfoques basados en hosts
- Detección de anomalías sobre actividad de red
 - Medidas de seguridad basadas en firmas
 - Medidas de seguridad basadas en comportamientos anómalos
- Clustering

ESTADO DEL ARTE

- Aprendizaje automático en clasificación de tráfico
 - Enfoques basados en flujos
 - Enfoques basados en hosts
- Detección de anomalías sobre actividad de red
 - Medidas de seguridad basadas en firmas
 - Medidas de seguridad basadas en comportamientos anómalos

- Clustering

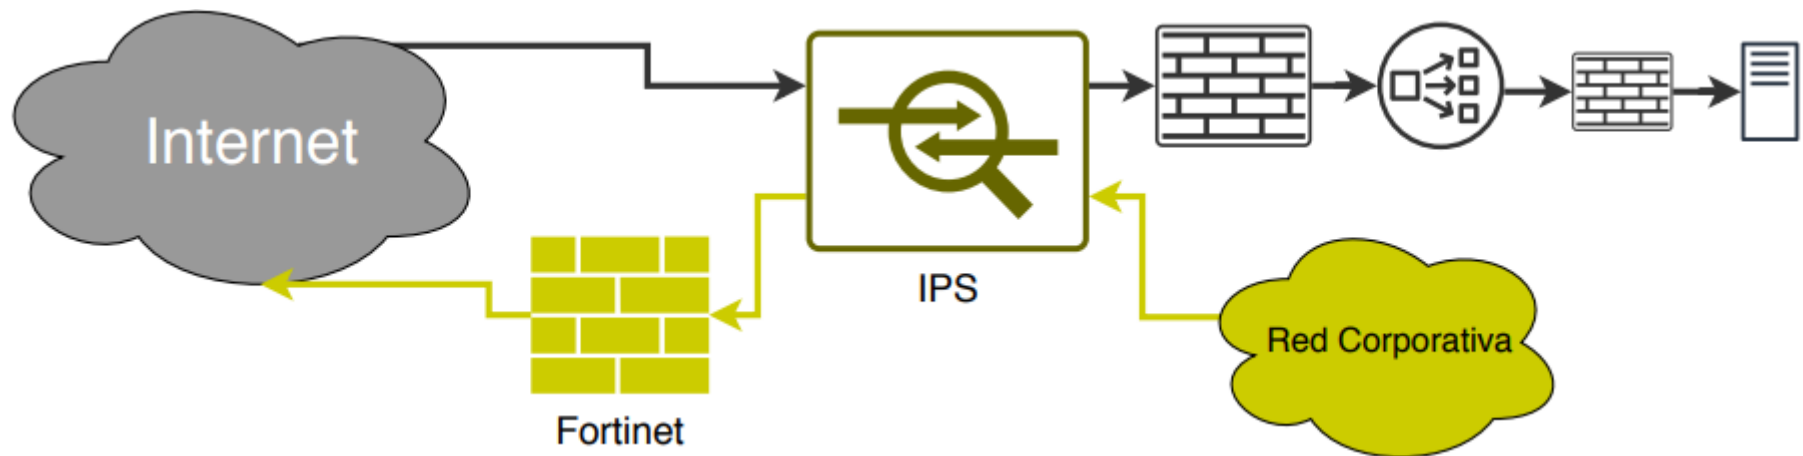
Ventajas del aprendizaje automático: autónomo, robusto, adaptable, puede hallar patrones complejos.

Alto coste de datos etiquetados a priori, conviene técnicas no supervisadas.

Numerosos trabajos demuestran la utilidad del clustering para esta tarea.


DESARROLLO DE LA CONTRIBUCIÓN

- PRESENTACIÓN DEL ESCENARIO



DESARROLLO DE LA CONTRIBUCIÓN

- EXTRACCIÓN DE SESIONES
 - Se extraen unos 20M sesiones/día.
 - Cada una se representa mediante el vector de características de la sesión.
 - Para el desarrollo se hizo un muestreo del 5% (1M sesiones por día) sobre 7 días de datos.



DESARROLLO DE LA CONTRIBUCIÓN

- PREPROCESADO PARA EL CLUSTERING
 - Consiste en resumir todas las sesiones del día para cada IP origen, aplicando agregaciones y calculando métricas.
 - Se obtienen matrices diarias.

DESARROLLO DE LA CONTRIBUCIÓN

- PREPROCESADO PARA EL CLUSTERING

| Característica | Explicación |
|--|--|
| Número de IPs destino únicas | IPs distintas a las que se ha conectado una IP origen |
| Protocolos usados | 2 si IP origen ha usado TCP y UDP, 1 si UDP, 0 si TCP |
| Número de puertos origen únicos | Puertos de nivel transporte usados por una IP origen |
| Número de puertos destino únicos | Puertos a los que se ha conectado una IP origen |
| Nivel de anomalía medio | Media de $N_{anomalía}$ en las sesiones de una IP origen |
| Nivel de amenaza medio | Media de $N_{amenaza}$ en las sesiones de una IP origen |
| Prioridad máxima | Prioridad más crítica vista en eventos de una IP origen |
| Número de eventos | Suma total de los eventos de una IP origen |
| Media de la duración de sesión | Duración media de las sesiones de una IP origen |
| Desv. estándar de la duración de sesión | Desv. est. de la duración de sesiones de una IP origen |
| Nº sesiones activas en horas nocturnas | Sesiones activas de 00:00 a 08:00 |
| Nº sesiones activas en horas de trabajo | Sesiones activas de 08:01 a 16:00 |
| Nº ses. activas en horas después del trabajo | Sesiones activas de 16:01 a 23:59 |

Tabla 1: Características con las que se resumen las sesiones en matrices diarias

DESARROLLO DE LA CONTRIBUCIÓN

• SELECCIÓN DE CARACTERÍSTICAS

| Característica | Explicación |
|--|--|
| Número de IPs destino únicas | IPs distintas a las que se ha conectado una IP origen |
| Protocolos usados | 2 si IP origen ha usado TCP y UDP, 1 si UDP, 0 si TCP |
| Número de puertos origen únicos | Puertos de nivel transporte usados por una IP origen |
| Número de puertos destino únicos | Puertos a los que se ha conectado una IP origen |
| Nivel de anomalía medio | Media de $N_{anomalía}$ en las sesiones de una IP origen |
| Nivel de amenaza medio | Media de $N_{amenaza}$ en las sesiones de una IP origen |
| Prioridad máxima | Prioridad más crítica vista en eventos de una IP origen |
| Número de eventos | Suma total de los eventos de una IP origen |
| Media de la duración de sesión | Duración media de las sesiones de una IP origen |
| Desv. estándar de la duración de sesión | Desv. est. de la duración de sesiones de una IP origen |
| Nº sesiones activas en horas nocturnas | Sesiones activas de 00:00 a 08:00 |
| Nº sesiones activas en horas de trabajo | Sesiones activas de 08:01 a 16:00 |
| Nº ses. activas en horas después del trabajo | Sesiones activas de 16:01 a 23:59 |

Tabla 1: Características con las que se resumen las sesiones en matrices diarias

– Son principalmente **6 características** las que influyen en la clasificación.

– Las características temporales no eran tan decisivas como se creía.

DESARROLLO DE LA CONTRIBUCIÓN

- EVALUACIONES EXPERIMENTALES
 - A través del método del codo y múltiples pruebas, se determina $k = 5$.
 - Se mide la calidad del clustering mediante:
 - Ratio de sumas de cuadrados ($SS_{between\ clusters} / SS_{total}$)
 - Coeficiente de silueta

RESULTADOS

- COMPOSICIÓN DE LOS CLUSTERS:
 - Muchas conexiones
 - Pocas conexiones
 - Sesiones UDP
 - Conexiones largas
 - Anomalías


- COMPOSICIÓN DE LOS CLUSTERS:

-
- A scatter plot showing the relationship between 'count_events' (x-axis) and 'avg_duration' (y-axis). The x-axis ranges from 0e+00 to 5e+05, and the y-axis ranges from 0 to 15000. The plot is categorized by five event types: 'anom' (red), 'few_cnxs' (green), 'long_duration' (blue), 'many_cnxs' (yellow), and 'udp' (purple). The 'anom' category shows two high-duration outliers at low event counts. The 'long_duration' category shows a dense cluster of points at low event counts and low duration. The 'many_cnxs' category shows a dense cluster of points at high event counts and low duration. The 'few_cnxs' and 'udp' categories show a few scattered points at low event counts and low duration.

RESULTADOS

- COMPOSICIÓN DE LOS CLUSTERS:


- Muchas conexiones
- Pocas conexiones
- **Sesiones UDP**
- Conexiones largas
- Anomalías



RESULTADOS

- COMPOSICIÓN DE LOS CLUSTERS:

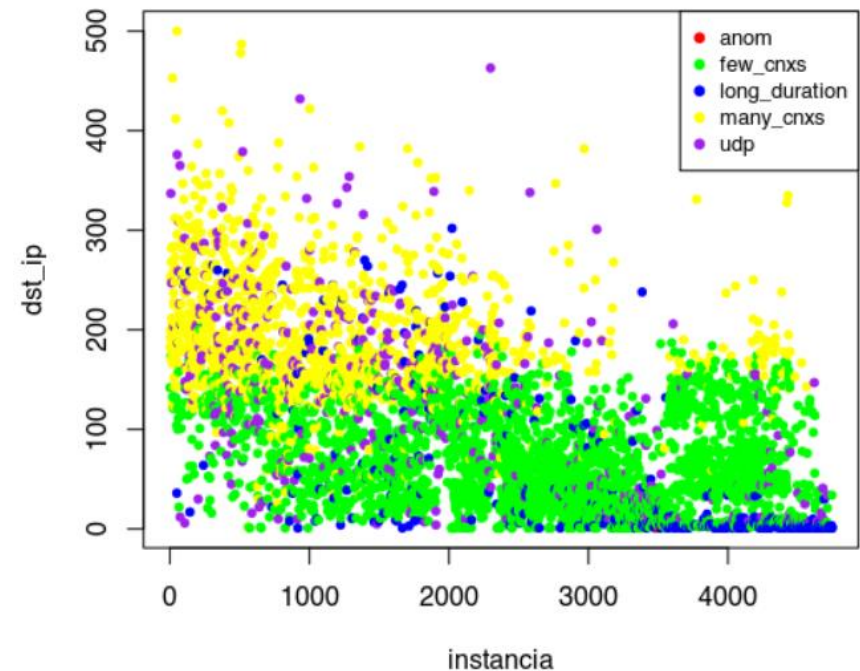
- Muchas conexiones
- Pocas conexiones
- Sesiones UDP
- Conexiones largas
- Anomalías



RESULTADOS

- COMPOSICIÓN DE LOS CLUSTERS:


- Muchas conexiones
- Pocas conexiones
- Sesiones UDP
- Conexiones largas
- Anomalías



RESULTADOS

- COMPOSICIÓN DE LOS CLUSTERS:

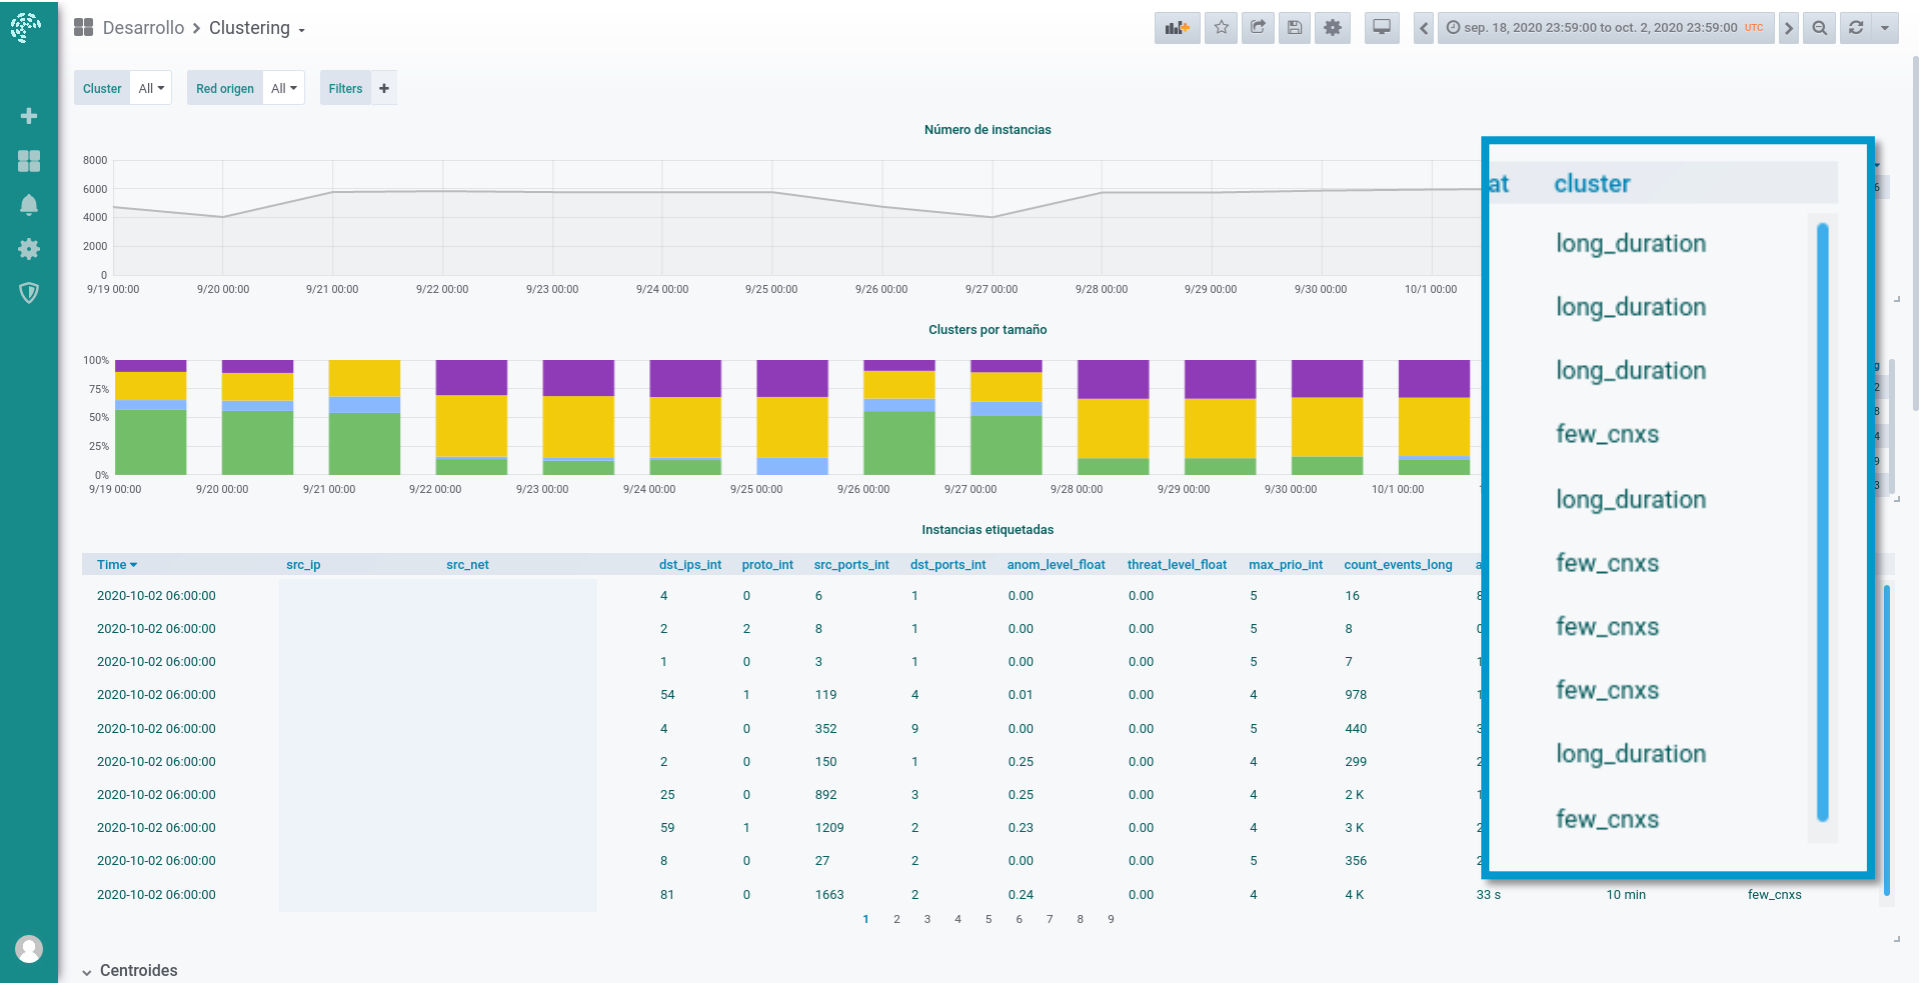
- Muchas conexiones
- **Pocas conexiones**
- Sesiones UDP
- Conexiones largas
- Anomalías



- **EVALUACIÓN EN ESCENARIO REAL**

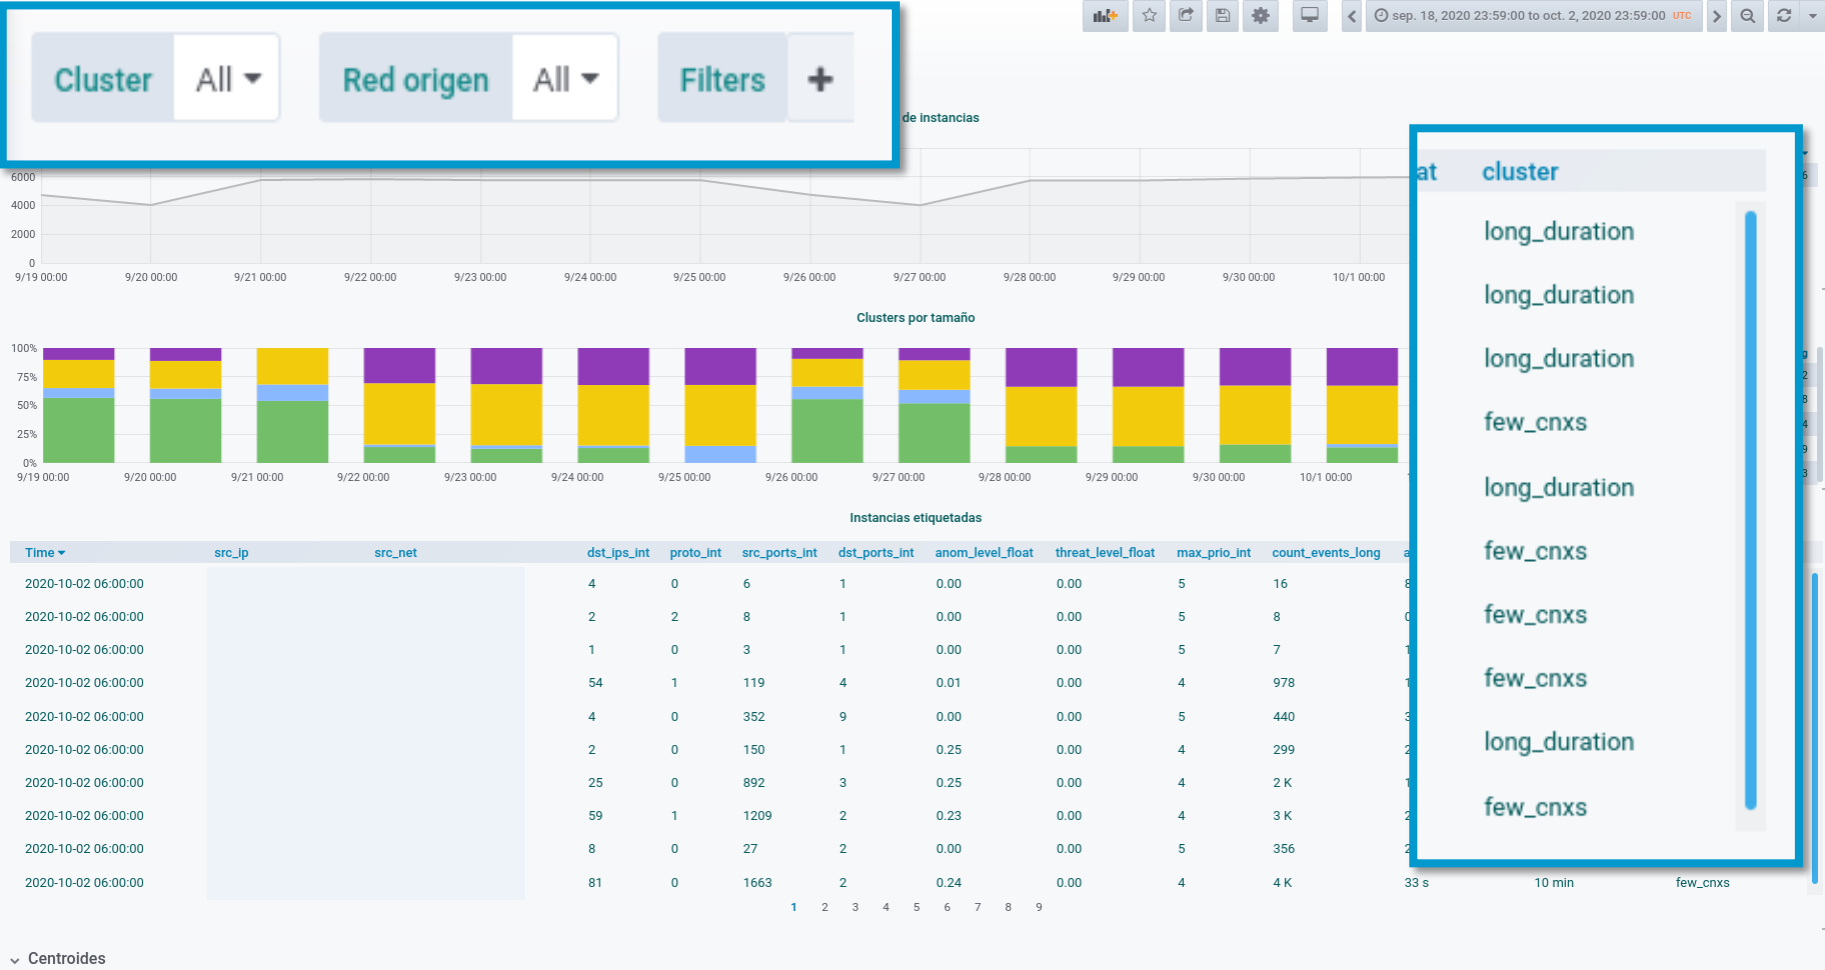
RESULTADOS

- EVALUACIÓN EN ESCENARIO REAL



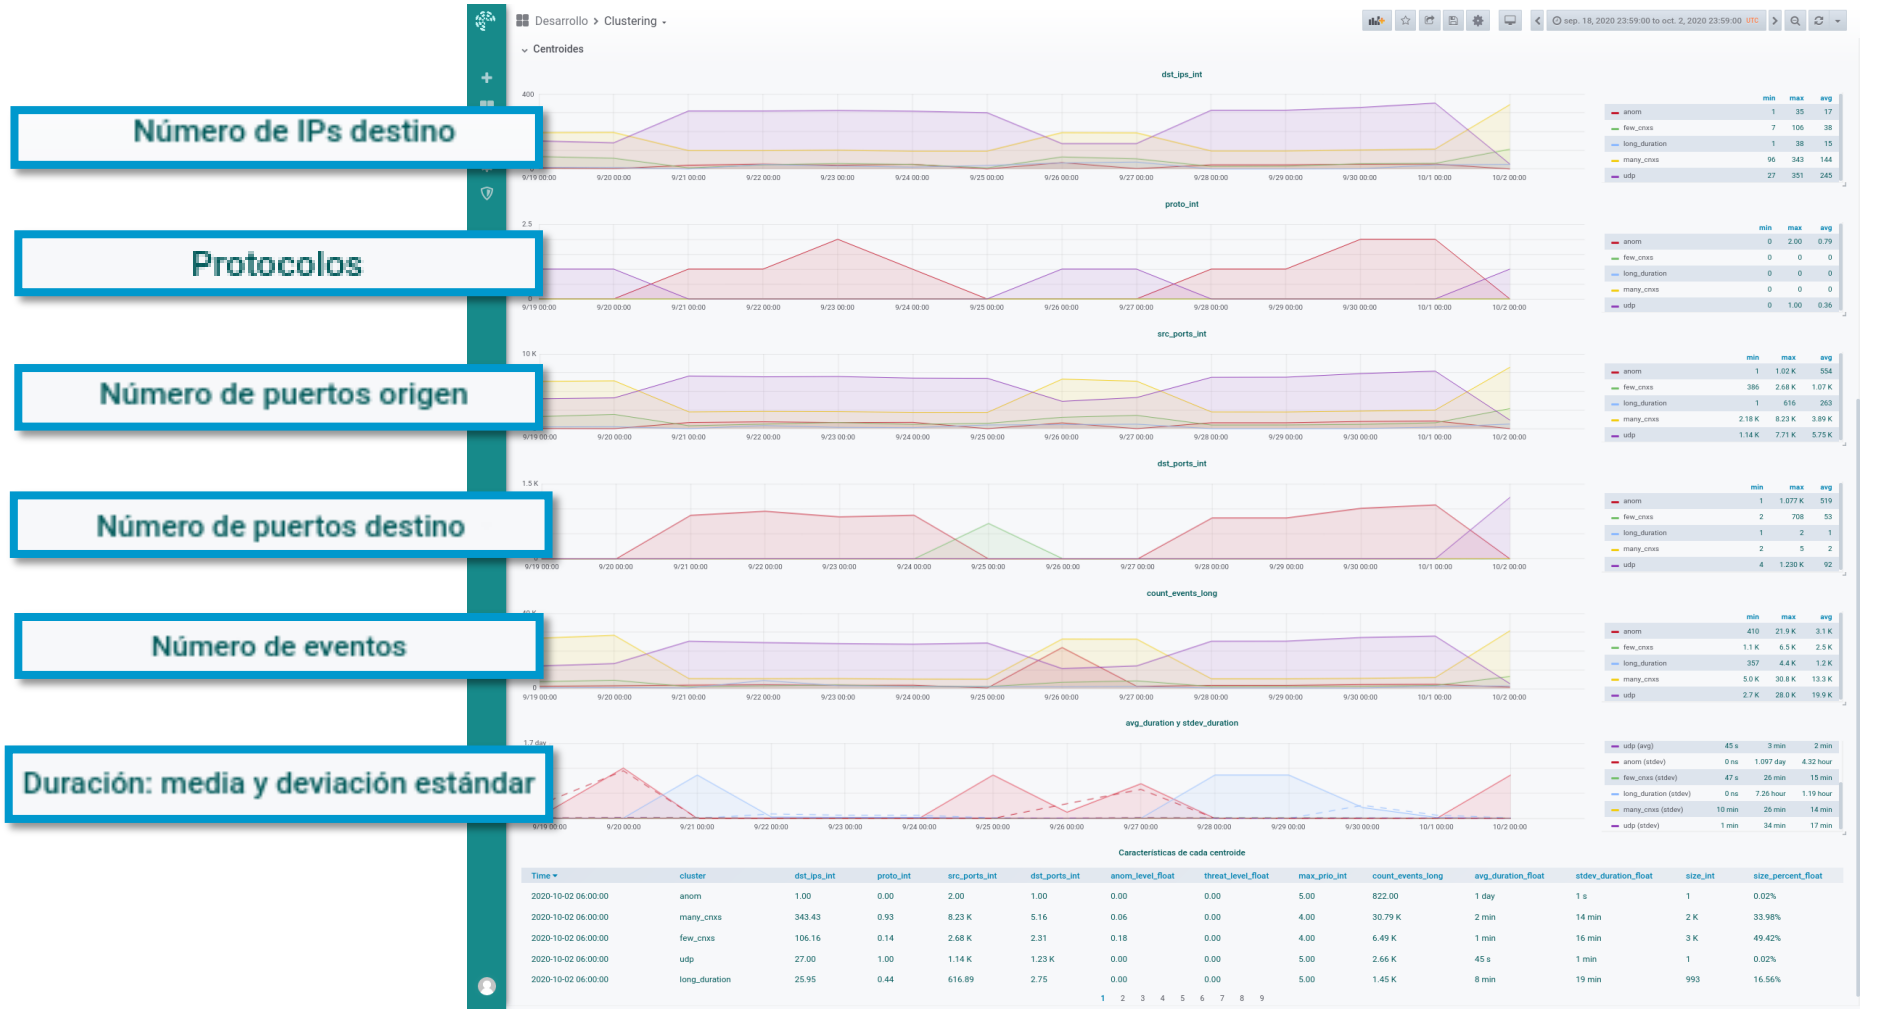
RESULTADOS

- EVALUACIÓN EN ESCENARIO REAL



RESULTADOS

- EVALUACIÓN EN ESCENARIO REAL



RESULTADOS

- EVALUACIÓN EN ESCENARIO REAL

cluster


anom

many_cnxs

few_cnxs

udp

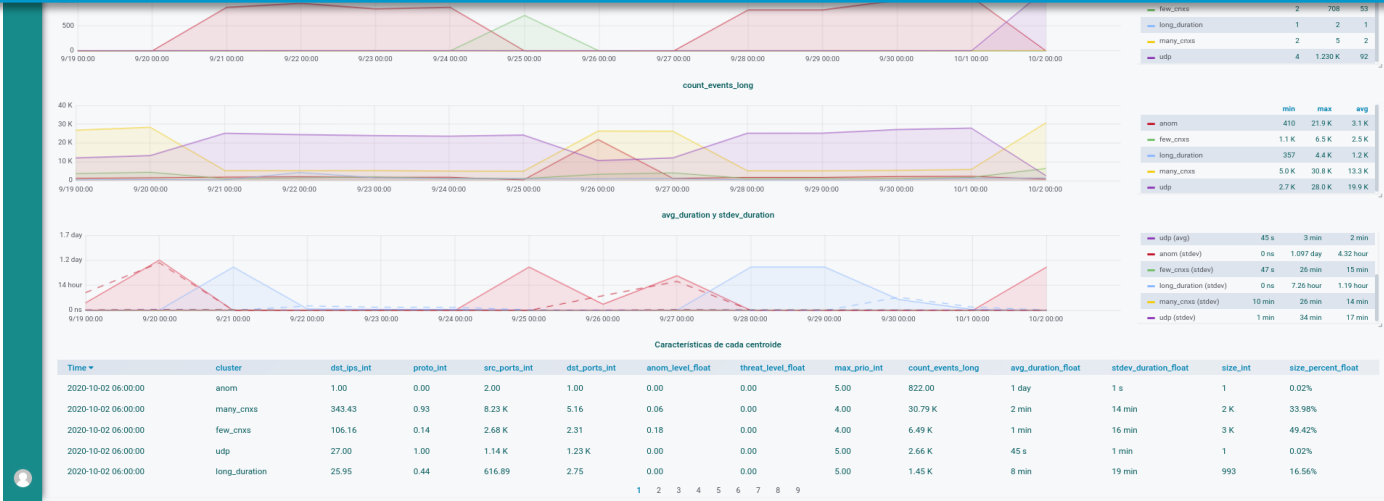
long_duration



Características de cada centroide

| dst_ips_int | proto_int | src_ports_int | dst_ports_int | anom_level_float | threat_level_float | max_prio_int | count_events_long | avg_duration_float | stdev_duration_float | size_int |
|-------------|-----------|---------------|---------------|------------------|--------------------|--------------|-------------------|--------------------|----------------------|----------|
| 1.00 | 0.00 | 2.00 | 1.00 | 0.00 | 0.00 | 5.00 | 822.00 | 1 day | 1 s | 1 |
| 343.43 | 0.93 | 8.23 K | 5.16 | 0.06 | 0.00 | 4.00 | 30.79 K | 2 min | 14 min | 2 K |
| 106.16 | 0.14 | 2.68 K | 2.31 | 0.18 | 0.00 | 4.00 | 6.49 K | 1 min | 16 min | 3 K |
| 27.00 | 1.00 | 1.14 K | 1.23 K | 0.00 | 0.00 | 5.00 | 2.66 K | 45 s | 1 min | 1 |
| 25.95 | 0.44 | 616.89 | 2.75 | 0.00 | 0.00 | 5.00 | 1.45 K | 8 min | 19 min | 993 |

1 2 3 4 5 6 7 8 9



CONCLUSIONES Y LÍNEAS FUTURAS

- Podemos clasificar en categorías relevantes las direcciones IP de una gran red empresarial, según su comportamiento de red.
- La categoría “anomalías” captura comportamiento sospechosos, aunque no necesariamente malintencionados.
- Esta aportación puede tener una aplicación práctica inmediata.

CONCLUSIONES Y LÍNEAS FUTURAS

La investigación podría continuar:

- Incorporando otros firewalls como fuente de datos, e incluso correlándolos.
- Aplicando este sistema de clustering a conexiones externas.
- Incrementando la granularidad dentro de las categorías normales mediante una segunda clusterización.

